

## Checkpoint 3 - Ensambles

En este checkpoint consistió construir diferentes clasificadores, KNN, SVM, RF y XGBoost, optimizar sus hiperparametros, y luego dos tipos de ensambles híbridos, Voting y Stacking.

Antes de comenzar, importamos los datasets y los preprocesamos de la misma forma que en el checkpoint anterior. De ahí, empezamos realizando un clasificador KNN. Para optimizar los hiperparametros variamos las métricas de distancia, el algoritmo usado, el tipo de peso, la cantidad de vecinos y el número máximo de muestras que almacena una hoja del árbol. Con esto obtuvimos un F1 Score de 0.80.

Luego creamos un clasificador SVM. Empezamos normalizando los datos, aplicando escalado estándar, aplicamos una reducción de la dimensionalidad, y después pasamos a optimizar los hiperparametros a utilizar en cada tipo de kernel, lineal, radial, y polinómica. Para hacer esto solo tomamos un 30% de los datos de train, ya que sinó el tiempo de ejecución aumentaba mucho. Con esto obtuvimos un F1 Score de 0.80, usando un kernel radial con un coeficiente gamma de 0.1 y un parámetro de regularización igual a 10.

Con XGBoost realizamos un proceso similar, llegando a un F1 Score de 0.82 y utilizando los siguientes hiperparámetros: 300 estimadores, un valor de alpha de 1, gamma y lambda igual a 1 y una máxima profundidad de 12.

Con Random Forest volvimos a repetir el proceso, logrando el mismo F1 Score de 0.82 pero con los siguientes hiperparámetros: 1800 estimadores, un número mínimo de 2 muestras requeridas para dividir un nodo, una máxima profundidad de 1, *entropy* como criterio de elección y la raíz cuadrada del número total de características como la cantidad máxima de características necesarias para dividir un nodo.

Finalmente, se entrenaron los ensambles híbridos. Para el ensamble de tipo Stacking se usaron KNN, XGBoost y RandomForest como modelos base y regresión logística como metamodelo. De esta manera se logró un F1 Score de 0.83. Para el ensamble de tipo Voting se usaron los mismos clasificadores y se obtuvo el mismo F1 Score de 0.83.

Para concluir, podemos ver que los ensambles que lograron los mejores resultados fueron los ensambles híbridos Stacking y Voting. Sin embargo, a lo largo del TP encontramos ciertas dificultades para ejecutar los modelos de manera consistente, lo cual impactó negativamente en la obtención de las métricas deseadas. Debido a esto, se tuvo que recurrir a la ejecución individual de cada modelo para poder obtener las matrices de confusión correspondientes. Sin embargo, las matrices de confusión se pueden encontrar en la notebook.