

# Conclusiones finales

A lo largo del trabajo se realizaron diversas tareas de procesamiento de datos y entrenamiento de modelos de clasificación con el fin de poder predecir si una reserva de hotel será cancelada. En el siguiente reporte se explicarán las conclusiones obtenidas y los aspectos más relevantes.

El preprocesamiento del conjunto de datos y el análisis exploratorio los consideramos los aspectos más cruciales de nuestro trabajo colectivo, ya que es lo que garantiza que los datos a usar sean confiables y puede mejorar significativamente la precisión y eficiencia de los modelos de clasificación. En estas fases, examinamos cuidadosamente los datos para comprender su naturaleza y tomamos las medidas necesarias para prepararlos adecuadamente para el análisis.

Reconocemos que los ensambles, que combinan las predicciones de varios modelos individuales para producir resultados más precisos y fiables, son una herramienta útil para la predicción. Sin embargo, para optimizar su rendimiento con mayor rapidez, se necesita una buena GPU y suficiente memoria. Lamentablemente, nuestro hardware estuvo limitado, especialmente cuando utilizamos plataformas como Colab, lo que nos impide explorar una amplia gama de alternativas.

Es importante señalar que se podrían haber aplicado otras técnicas de modelado de ensambles más avanzadas, como Gradient Boosting Machines (GBM), LightGBM o CatBoost, para aumentar la eficacia y generalizabilidad de nuestros resultados. Además, elegir la arquitectura adecuada para las redes neuronales es fundamental, pero nos resultó difícil determinar por qué una arquitectura es mejor que otra.

A continuación, comparamos los modelos desarrollados en función de sus puntuaciones F1:

- Árbol de decisiones: 0.76
- KNN, SVM y XGBoost obtuvieron todos una puntuación de 0,80.
- Random Forest: 0.82
- Stacking: KNN, XGBoost y RandomForest: 0,83
- Voting: KNN, XGBoost y RandomForest: 0.83
- SGD: 0.7504
- Adam: 0.7986
- Adadelta: 0.7502
- RMSprop: 0.8011
- Red neuronal optimizada: 0.81

Los dos mejores resultados de las puntuaciones mencionadas fueron Stacking (KNN, XGBoost y RandomForest): 0.83 e Voting (KNN, XGBoost y RandomForest) : 0.83

Estos dos métodos ensambles obtuvieron resultados excepcionales en la tarea de predicción, como indica su puntuación F1 de 0,83.

Con respecto al manejo de outliers, consideramos que hicimos un buen trabajo al tomar como fuente de verdad el paper acompañante del dataset para evaluar los casos irregulares y tomar decisiones que se apeguen a las indicaciones del paper, sin embargo en retrospectiva consideramos que pudimos haber sido un poco más estrictos con los outliers y quizás esto hubiese sido reflejado en un mejor score (aún así los obtenidos fueron muy buenos) o menor ruido para los modelos que son considerados más precisos y eficientes, por ejemplo, ensambles y más recientemente redes neuronales.

La conclusión final es que los modelos Stacking y Voting, construidos con KNN, XGBoost y RandomForest, fueron los más óptimos.